

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

FACULTAD DE CIENCIAS E INGENIERÍA

INGENIERÍA MECATRÓNICA



**LABORATORIO : INTELIGENCIA ARTIFICIAL Y VISIÓN POR
COMPUTADORA**

1MTR56

AUTOMATIZACIÓN INDUSTRIAL INTELIGENTE B

Tabla de contenido

1	Inteligencia Artificial: Redes Neuronales Convolucionales	2
1	Introducción	2
2	Preparación del entorno en VS Code	2
3	Redes neuronales convolucionales	2
4	Entrenamiento y evaluación	3
5	Aumentación de datos	4
6	Experiencia guiada	4
6.1	Notebook 1: CNN desde cero	5
6.2	Notebook 2: aumentación de datos	6
6.3	Notebook 3: clasificador de tapitas	7
6.4	Cierre: discusión crítica	7
7	Cierre: el límite del entrenamiento desde cero	7
2	Visión por Computadora: Transfer Learning y Beckhoff	9
8	Introducción	9
9	Aprendizaje por transferencia	9
10	El dataset de tapitas	10
11	Protocolo ADS y comunicación con Beckhoff	10
11.1	Configuración previa en TwinCAT	10
11.2	La librería pyads	11
12	Integración: del clasificador a la acción del brazo	11
13	Experiencia guiada	12
14	Anexos	13

Parte 1

Inteligencia Artificial: Redes Neuronales Convolucionales

1 Introducción

Esta guía introduce los fundamentos de la *visión por computadora* basada en aprendizaje profundo y los aplica a un problema de clasificación de imágenes con *redes neuronales convolucionales* (CNN). Constituye la **Parte 1** del laboratorio: se entrena una CNN *desde cero*; la Parte 2 introducirá el aprendizaje por transferencia sobre el mismo dominio.

Materiales. Python 3.10 con el entorno del laboratorio; el dataset de botellas provisto en `data/botellas/`; y los tres notebooks de la carpeta `parte1_ia/` (Notebook 1 a Notebook 3). Cada notebook explica su código en detalle; esta guía es la referencia teórica y describe *qué* se hace y *cuánto* aporta a la evaluación.

2 Preparación del entorno en VS Code

El único requisito delicado es usar un entorno virtual con la **versión correcta de Python** (3.10 o 3.11): con otra versión, TensorFlow no se instala correctamente.

1. Abrir la carpeta del proyecto en **Visual Studio Code**.
2. *Command Palette* (Ctrl+Shift+P) → Python: Create Environment → Venv → elegir un intérprete **Python 3.10** o **3.11**. Cuando VS Code lo solicite, marcar `requirements.txt` para que instale las dependencias en ese entorno.
3. En cada notebook, Select Kernel (arriba a la derecha) y elegir el entorno `.venv` recién creado.

Con el entorno correcto seleccionado, las celdas de `import` de los notebooks funcionan directamente (las dependencias ya quedaron instaladas al crear el entorno). Para confirmar la versión:

```
import sys, tensorflow as tf
print(sys.version)      # 3.10.x o 3.11.x
print(tf.__version__)   # 2.20.0
```

3 Redes neuronales convolucionales

Una CNN aprende a extraer características visuales directamente de los píxeles, sin ingeniería manual de *features*. Se compone de tres tipos de capas (Figura 1):

- **Convolución** (Conv2D): aplica filtros que se deslizan sobre la imagen y detectan patrones locales —bordes, texturas, formas—. Los filtros se aprenden durante el entrenamiento (Figura 2).
- **Pooling** (MaxPooling2D): reduce la resolución conservando la información dominante, lo que aporta robustez y disminuye el cómputo (Figura 3).
- **Capas densas** (Dense): combinan las características extraídas; la capa de salida usa *softmax* para producir una probabilidad por clase.

La función de activación *ReLU* introduce la no linealidad entre capas; sin ella la red colapsaría a una única transformación lineal (Figura 4).




Figura 1. Arquitectura típica de una CNN: bloques de convolución y pooling extraen características de complejidad creciente; las capas densas producen la clasificación. Fuente: Wikimedia Commons (CC BY-SA).

Entrada (5 × 5)	Kernel Sobel-x (3 × 3)	Feature map (3 × 3)																																											
<table><tr><td>195</td><td>45</td><td>87</td><td>171</td><td>123</td></tr><tr><td>112</td><td>162</td><td>43</td><td>92</td><td>109</td></tr><tr><td>130</td><td>62</td><td>156</td><td>187</td><td>88</td></tr><tr><td>196</td><td>147</td><td>155</td><td>192</td><td>20</td></tr><tr><td>95</td><td>75</td><td>26</td><td>39</td><td>64</td></tr></table>	195	45	87	171	123	112	162	43	92	109	130	62	156	187	88	196	147	155	192	20	95	75	26	39	64	<table><tr><td>-1</td><td>+0</td><td>+1</td></tr><tr><td>-2</td><td>+0</td><td>+2</td></tr><tr><td>-1</td><td>+0</td><td>+1</td></tr></table>	-1	+0	+1	-2	+0	+2	-1	+0	+1	<table><tr><td>-220</td><td>111</td><td>100</td></tr><tr><td>-58</td><td>225</td><td>-205</td></tr><tr><td>-125</td><td>179</td><td>100</td></tr></table>	-220	111	100	-58	225	-205	-125	179	100
195	45	87	171	123																																									
112	162	43	92	109																																									
130	62	156	187	88																																									
196	147	155	192	20																																									
95	75	26	39	64																																									
-1	+0	+1																																											
-2	+0	+2																																											
-1	+0	+1																																											
-220	111	100																																											
-58	225	-205																																											
-125	179	100																																											

Figura 2. Operación de convolución: un filtro recorre la imagen y produce un mapa de características. Fuente: Stanford CS231n.

4 Entrenamiento y evaluación

El entrenamiento ajusta los filtros minimizando una *función de pérdida* (*categorical crossentropy* para clasificación multiclase) mediante *backpropagation* y un optimizador (*Adam* por defecto). El proceso se repite durante varias *épocas* sobre lotes (*batches*) de imágenes.

El desempeño se mide sobre un conjunto de **validación** independiente. La *accuracy* y la **matriz de confusión** revelan no solo cuánto acierta el modelo, sino dónde se




Figura 3. Max pooling: cada región se resume por su valor máximo, reduciendo la resolución.
Fuente: elaboración propia.




Figura 4. Funciones de activación habituales. *ReLU* es la más usada en capas convolucionales. Fuente: elaboración propia.

confunde. Si la accuracy en entrenamiento es alta pero la de validación es baja, el modelo sufre *overfitting*: memoriza en lugar de generalizar.

5 Aumentación de datos


La *data augmentation* genera variaciones de las imágenes de entrenamiento — rotaciones, desplazamientos, cambios de brillo, zoom— para que el modelo generalice mejor con pocos datos. Es la primera defensa contra el *overfitting* sin modificar la arquitectura.

6 Experiencia guiada

El trabajo se desarrolla en tres notebooks que la pareja ejecuta y completa. La indicación es la misma para todos: **ejecutar el notebook de principio a fin, completar las celdas marcadas como «completar» y responder por escrito las preguntas conceptuales**. Como los notebooks ya vienen implementados, **la nota evalúa la comprensión**: las respuestas a las preguntas conceptuales y la interpretación y justificación de los resultados, no la simple ejecución. La rúbrica completa está en la *Ficha de Evaluación*: la Parte 1 aporta **10 puntos** y la Parte 2 otros 10, para una nota

sobre 20.

Los Notebooks 1 y 2 usan el dataset de botellas (vidrio/plástico) provisto; el Notebook 3 usa un dataset de tapitas construido por la propia pareja. El dataset se organiza en subcarpetas por clase dentro de train/ y validation/, de modo que ImageDataGenerator infiera las etiquetas automáticamente:



6.1 Notebook 1: CNN desde cero

Recorre el ciclo completo de una CNN entrenada desde cero: carga del dataset, definición y compilación de la arquitectura (Figura 5: bloques Conv2D + MaxPooling2D, Flatten, capa densa con *dropout* y salida *softmax*), entrenamiento, evaluación con matriz de confusión y predicción sobre imágenes propias (Figuras 6 y 7).




Figura 5. Arquitectura de la CNN del laboratorio. Fuente: elaboración propia (NN-SVG).

Etapa notebook)	(secciones	del	Qué se realiza	Puntos
1. Arquitectura y entrenamiento (secciones 3–6)			Definir y compilar la CNN, entrenar y analizar las curvas de <i>loss/accuracy</i> y la matriz de confusión sobre validación.	1.5
2. Evaluación con datos propios (sección 7)			Clasificar cuatro fotografías capturadas por la pareja en condiciones variadas e identificar aciertos y fallos.	1.5




Figura 6. Curvas de aprendizaje esperadas sobre el dataset de botellas. Fuente: elaboración propia.




Figura 7. Matriz de confusión sobre validación: la diagonal son aciertos. Fuente: elaboración propia.

6.2 Notebook 2: aumentación de datos

Retoma el clasificador anterior para evidenciar y mitigar el *overfitting*: reproduce el sobreajuste del modelo base, selecciona transformaciones de aumentación pertinentes, reentrena y compara el desempeño frente al modelo sin aumentar.

Etapa notebook)	(secciones del	Qué se realiza	Puntos
3. Data augmentation (secciones 2–5)		Diagnosticar el <i>overfitting</i> del modelo base, seleccionar transformaciones justificadas, reentrenar y comparar curvas frente al modelo base.	2.5

6.3 Notebook 3: clasificador de tapitas

Introduce un dataset propio: tapitas de colores (**rojo, azul, amarillo**) más una clase fondo (imágenes sin tapita). La pareja graba un video corto por color, el notebook extrae los *frames* a `data/tapitas/<clase>/` (descartando los borrosos), divide en *train/validation* y entrena una CNN desde cero. El modelo se exporta a `modelos/` para reutilizarlo en la Parte 2.

Protocolo de captura: iluminación y fondos variados, distancia 10–40 cm, ángulos diversos, una sola tapita por imagen y al menos 50 muestras por clase.

Etapa (pasos del notebook)	Qué se realiza	Puntos
4. Captura y preparación del dataset (pasos 1–2)	Grabar un video por color, extraer los frames a <code>data/tapitas/</code> y reportar el conteo por clase.	1.0
5. Entrenamiento y evaluación CNN (pasos 3–4)	Dividir <i>train/validation</i> , entrenar la CNN, analizar curvas y matriz de confusión, y exportar el modelo.	2.0

6.4 Cierre: discusión crítica

A partir de los resultados, la pareja formula al menos dos hipótesis técnicas sobre las causas de los errores (sesgos del dataset, sensibilidad a la iluminación, límites de la arquitectura) y propone dos estrategias de mejora sin cambiar la arquitectura. Se documenta en la Ficha de Evaluación (**1.5 puntos**).

Distribución de la nota de la Parte 1	Puntos
Notebook 1 — <code>notebook1_cnn_desde_cero.ipynb</code>	3.0
Notebook 2 — <code>notebook2_data_augmentation.ipynb</code>	2.5
Notebook 3 — <code>notebook3_clasificador_tapitas.ipynb</code>	3.0
Discusión crítica	1.5
Total Parte 1	10.0

7 Cierre: el límite del entrenamiento desde cero

La evaluación sobre datos propios suele revelar un resultado aleccionador: el modelo alcanza buena *accuracy* en validación, pero **falla ante condiciones reales** de iluminación, fondo o ángulo distintas a las del entrenamiento. La aumentación (Notebook 2) mitiga el problema pero no lo resuelve: una CNN entrenada desde cero necesita muchas más imágenes de las que es razonable capturar a mano.

Ese es el límite que motiva la **Parte 2**: en lugar de aprender todos los filtros desde cero, se parte de una red ya entrenada sobre millones de imágenes y se reutiliza su

conocimiento —*aprendizaje por transferencia*—, obteniendo clasificadores robustos con apenas unos cientos de imágenes por clase. Sobre esa técnica se construye el sistema de control de calidad de la segunda parte, reutilizando el dataset de tapitas del Notebook 3.

Parte 2

Visión por Computadora: Transfer Learning y Beckhoff

8 Introducción

Esta es la **Parte 2** del laboratorio: visión por computadora aplicada al control de calidad. Se reutiliza el dataset de tapitas de la Parte 1, pero ahora el modelo se entrena con *aprendizaje por transferencia* (MobileNetV2) y el resultado se envía a un IPC **Beckhoff** por el protocolo **ADS** para accionar un brazo robótico.

Materiales. Los tres notebooks de parte2_vision/ (Notebook 4 a Notebook 6); la librería pyads; y un proyecto TwinCAT con el IPC Beckhoff.

9 Aprendizaje por transferencia

En lugar de entrenar una red desde cero, el *transfer learning* parte de un modelo ya entrenado sobre millones de imágenes (**MobileNetV2**, sobre ImageNet) y reutiliza los filtros que este aprendió. Se procede en dos fases (Figura 8):

- **Feature extraction:** se *congela* el *backbone* preentrenado y se entrena solo un cabezal nuevo (capa densa *softmax*) para las clases del problema. Pocas épocas bastan.
- **Fine-tuning:** se *descongelan* las últimas capas del *backbone* y se reentrena con un *learning rate* pequeño, para afinar las características de alto nivel al dominio de las tapitas sin destruir lo aprendido.

La ventaja es decisiva: se obtienen clasificadores robustos con apenas unos cientos de imágenes por clase, donde una CNN desde cero necesitaría miles.




Figura 8. Aprendizaje por transferencia: se reutiliza el *backbone* preentrenado y se sustituye el clasificador final. Fuente: elaboración propia.

10 El dataset de tapitas

Se reutiliza el dataset construido en la Parte 1 (Notebook 3): cuatro clases en orden alfabético —amarillo, azul, fondo, rojo—, con la división 80 % entrenamiento / 20 % validación. La clase fondo (imágenes sin tapita) es defensiva: evita que el modelo fuerce un color cuando no hay objeto y **no activa ninguna salida** del PLC. Si el dataset resultó escaso, conviene ampliarlo con más variación de iluminación, fondo y ángulo.

11 Protocolo ADS y comunicación con Beckhoff

El **ADS** (*Automation Device Specification*) es el protocolo de Beckhoff para intercambiar datos con el runtime TwinCAT. Permite acceder a las variables del PLC por su **nombre simbólico** (dentro de una *Global Variable List*, GVL), sobre TCP/IP y desde cualquier lenguaje; desde Python se usa la librería pyads (Figura 9).




Figura 9. Arquitectura del protocolo ADS: las aplicaciones cliente acceden a las variables del PLC a través del *router* de TwinCAT. Fuente: Beckhoff Automation.

11.1 Configuración previa en TwinCAT

Para que Python pueda escribir en el IPC, del lado TwinCAT se debe:

1. Declarar en una GVL llamada VARIABLES tres variables BOOL: bRojo, bAzul, bAmarillo.
2. Configurar una *route* ADS entre la PC y el IPC (AMS Net ID y puerto 851).
3. Construir un **HMI** en TwinCAT con una **lámpara por color**, cada una enlazada a su variable BOOL, para verificar visualmente que el clasificador escribe la variable correcta.

11.2 La librería pyads

El patrón básico de conexión y escritura se muestra en el Script 1. Los nombres en `write_by_name()` deben coincidir *exactamente* con los de la GVL (mayúsculas incluidas).

Script 1. Conexión y escritura básica con pyads.

```
import pyads

ipc = pyads.Connection('192.168.57.231.1.1', 851)  # AMS Net ID del IPC
ipc.open()

ipc.write_by_name('VARIABLES.bRojo',      True,  pyads.PLCTYPE_BOOL)
ipc.write_by_name('VARIABLES.bAzul',      False, pyads.PLCTYPE_BOOL)
ipc.write_by_name('VARIABLES.bAmarillo', False, pyads.PLCTYPE_BOOL)

ipc.close()
```

12 Integración: del clasificador a la acción del brazo

El sistema opera bajo un contrato simple: el clasificador procesa el *frame* de la cámara y, si la confianza supera un umbral configurable (por defecto 0.6), escribe True en la variable del color predicho y False en las otras dos; si la clase es fondo o la confianza es baja, las tres quedan en False. El PLC detecta el flanco ascendente, activa la salida digital correspondiente y el brazo deposita la tapita en su zona. El Script 2 integra captura, predicción y escritura ADS.

Script 2. Bucle principal: captura, predicción y escritura ADS.

```
import cv2, numpy as np, pyads
from tensorflow.keras.models import load_model
from tensorflow.keras.applications.mobilenet_v2 import preprocess_input

UMBRAL = 0.6
IMG_SIZE = 128  # igual que al entrenar (NB4)
)
CLASES = ['amarillo', 'azul', 'fondo', 'rojo']  # orden alfabético
VAR_POR_CLASE = {  # 'fondo' no activa ninguna
    salida
    'rojo': 'VARIABLES.bRojo',
    'azul': 'VARIABLES.bAzul',
    'amarillo': 'VARIABLES.bAmarillo',
}

modelo = load_model('modelo_tapitas.h5')
ipc = pyads.Connection('192.168.57.231.1.1', 851)
ipc.open()

cam = cv2.VideoCapture(0)
try:
    while True:
        ok, frame = cam.read()
```

```

if not ok:
    break
# Preprocesamiento MobileNetV2: BGR->RGB, resize y normalizar a [-1,
  1]
img = cv2.cvtColor(cv2.resize(frame, (IMG_SIZE, IMG_SIZE)), cv2.
  COLOR_BGR2RGB)
x = np.expand_dims(preprocess_input(img.astype('float32')), axis=0)

pred = modelo.predict(x, verbose=0)[0]
idx = int(np.argmax(pred))
clase, confianza = CLASES[idx], float(pred[idx])

# Activa el BOOL del color detectado si supera el umbral; el resto en
  False.
activo = VAR_POR_CLASE.get(clase) if confianza >= UMBRAL else None
for var in VAR_POR_CLASE.values():
    ipc.write_by_name(var, var == activo, pyads.PLCTYPE_BOOL)

cv2.putText(frame, f"{clase} ({confianza:.2f})", (10, 30),
  cv2.FONT_HERSHEY_SIMPLEX, 0.8, (0, 255, 0), 2)
cv2.imshow('Clasificador', frame)
if cv2.waitKey(1) & 0xFF == ord('q'):
    break
finally:
    cam.release(); cv2.destroyAllWindows()
    for var in VAR_POR_CLASE.values():
        ipc.write_by_name(var, False, pyads.PLCTYPE_BOOL)
    ipc.close()

```

13 Experiencia guiada

La pareja ejecuta y completa los tres notebooks de la Parte 2. Como en la Parte 1, y dado que los notebooks ya están implementados, **la nota evalúa la comprensión**: las respuestas a las preguntas conceptuales y la interpretación de los resultados, no la simple ejecución. La Parte 2 aporta **10 puntos**.

Actividad (herramienta)	Qué se realiza	Puntos
1. Feature extraction (notebook4, secc. 2–6)	Reutilizar el dataset de la Parte 1, construir el modelo con <i>backbone</i> MobileNetV2 congelado, entrenar el cabezal y evaluar con curvas y matriz de confusión.	3.0
2. Fine-tuning (notebook4, secc. 4–5)	Descongelar los últimos <i>layers</i> , reentrenar con <i>learning rate</i> pequeño y comparar contra la fase anterior y contra la CNN del Notebook 3.	2.0
3. Conexión ADS y HMI (TwinCAT + pyads)	Declarar las tres BOOL en la GVL, construir el HMI con una lámpara por color y escribirlas desde Python (Script 1), verificando el encendido.	2.0
4. Demostración integrada (notebook6 + brazo)	Ejecutar el bucle de inferencia (Script 2) con la cámara: cada color detectado activa su BOOL y dispara la acción del brazo. Grabar un video.	2.5
5. Discusión final	Reflexionar sobre cómo aplicar el sistema en el proyecto integrador de automatización.	0.5
Total Parte 2		10.0

14 Anexos

Anexo B1. Variables del proyecto TwinCAT

Variable	Tipo	Descripción
bRojo	BOOL	Verdadero al detectar una tapita roja sobre el umbral.
bAzul	BOOL	Verdadero al detectar una tapita azul sobre el umbral.
bAmarillo	BOOL	Verdadero al detectar una tapita amarilla sobre el umbral.

Deben declararse dentro de la GVL VARIABLES; el nombre de la GVL forma parte del identificador usado en `write_by_name()`.

Anexo B2. Diagnóstico de errores comunes

Error	Causa y solución
Missing ADS routes (7)	Falta la <i>route</i> ADS entre la PC y el IPC (<code>open()</code> no la valida; el error aparece al leer/escribir). Crearla en TwinCAT (bandeja) → Router → Edit Routes → Add Route.
AdsError: symbol not found	El nombre en <code>write_by_name</code> no coincide con la GVL. Verificar mayúsculas y el prefijo VARIABLES.
El brazo no se dispara	La variable se escribe pero el POU del PLC no actúa sobre ella. Verificar la lógica en TwinCAT.
Confianza alta pero clase incorrecta	Dataset poco diverso. Capturar más muestras en condiciones variadas.